

KIẾN TRÚC HỆ THỐNG

Hệ Thống RAG & Coding Agent

Từ nhu cầu hỏi đáp tài liệu thực tế đến thiết lập nền tảng AI Agent & mô hình định tuyến
Model Router an toàn, hiệu quả.

Mục Tiêu Thiết Kế Hệ Thống



Một URL Duy Nhất

Triển khai qua cổng ngrok thông minh, cung cấp giao diện Web và API hoàn chỉnh từ Máy 2 mà không cần cấu hình mạng phức tạp.



Model Selector Tối Ưu

Tự động lựa chọn mô hình cục bộ (Local), MiMo Cloud hoặc OpenAI. Ưu tiên Local nhằm tối ưu chi phí, tự động fallback linh hoạt.



Bảo Mật Agent Cô Lập

Xây dựng Coding Agent chạy độc lập, kiểm soát chặt chẽ bằng ranh giới bảo mật nghiêm ngặt qua khóa API bảo mật chuyên biệt.

Hệ Sinh Thái Công Nghệ Sử Dụng

TẦNG VAI TRÒ	CÔNG NGHỆ TÍCH HỢP	VAI TRÒ BẢN CHẤT TRONG PIPELINE
Frontend	React + Vite + react-markdown	Giao diện người dùng thời gian thực, hiển thị câu hỏi và trích nguồn tin cậy.
API & Routing	FastAPI + LiteLLM	Cung cấp API Streaming qua SSE, proxy định tuyến mô hình chuẩn OpenAI.
RAG Core	Docling + BGE-M3 + Qdrant DB	Trích xuất Markdown nâng cao, tạo Vector Embeddings đa ngôn ngữ và lưu trữ tìm kiếm.
Agent Loop	LangGraph + MCP Filesystem/Git	Lập trình và tương tác với hệ thống tệp và quản lý mã nguồn thông qua giao thức MCP.
Hạ Tầng	Docker Compose + Systemd	Đóng gói dịch vụ Qdrant/LiteLLM, đảm bảo dịch vụ tự khởi động bền bỉ.

Định TUYẾN & Quản Lý Mô Hình

NHÓM MÔ HÌNH	BACKEND ROUTE	CHUỖI ĐỊNH TUYẾN & FALLBACK PHÍA SAU
Tự Động (Auto)	auto-model	Ưu tiên chạy Gemma4 Local → Tự động Fallback MiMo Pro → Fallback OpenAI GPT-4o mini.
Local Gemma	local-gemma	Gọi trực tiếp Ollama / Gemma4 cài đặt cục bộ trên Máy 1 nhằm bảo mật dữ liệu tuyệt đối.
MiMo Cloud	mimo-pro	Định tuyến tới API Xiaomi MiMo 2.5 Pro cho hiệu suất cao với chi phí tối ưu.
OpenAI Cloud	openai-model	Sử dụng dịch vụ toàn cầu GPT-4o mini khi yêu cầu các tác vụ lập luận phức tạp nhất.
Coding Agent	coding-model	Nhóm mô hình tối ưu cho Agent viết code (ưu tiên Gemma4, fallback OpenAI).

Kiến Trúc Phân Tách Vật Lý

Xử Lý & Giao Tiếp (Máy 2)

Nơi tiếp nhận trực tiếp và đảm bảo an toàn cho các tác vụ công khai ngoài Internet:

- Mở public cổng 8001 duy nhất qua kênh ngrok HTTPS.
- Chạy React SPA & FastAPI để tiếp nhận tệp tin, phân tách phiên làm việc.
- Giữ LiteLLM (:4000) và Qdrant (:6333) chạy nội bộ ẩn, tăng tính bảo mật.

Tính Toán LLM (Máy 1 & Cloud)

Nơi tập trung tài nguyên GPU và tích hợp các bên dịch vụ thứ ba:

- Máy 1 chạy Gemma4 qua Ollama, phục vụ xử lý Offline không mất chi phí.
- Mạng lưới Cloud kết nối an toàn tới Xiaomi MiMo API & OpenAI Endpoint.
- Ngăn chặn truy cập trực tiếp từ người dùng ngoài hệ thống tới LLM.

Quy Trình Xử Lý RAG Khép Kín



Chiến Lược Định Tuyến Dự Phòng



Ưu Tiên 1: Local Gemma4

Mặc định điều hướng tác vụ xuống mô hình Local chạy trên Máy 1. Giữ an toàn dữ liệu nội bộ và tối ưu hoàn toàn chi phí vận hành.



Dự Phòng 1: MiMo Cloud

Khi máy Local quá tải hoặc mất kết nối, hệ thống lập tức tự động định tuyến nhiệm vụ sang API MiMo 2.5 Pro với độ ổn định cao.



Dự Phòng 2: OpenAI GPT

Lớp lá chần cuối cùng đảm bảo độ sẵn sàng của hệ thống. Luôn sẵn sàng hồi đáp khi cả hai hạ tầng trên gặp sự cố kỹ thuật.

Bản Đồ Định Tuyến Cổng Public 8001


ĐƯỜNG DẪN REST API / WEB	PHƯƠNG THỨC	MÔ TẢ CHỨC NĂNG HOẠT ĐỘNG THỰC TẾ
/	GET	Phục vụ giao diện người dùng đơn trang React SPA hoạt động mượt mà.
/health, /models	GET	Kiểm tra trạng thái hệ thống và truy xuất danh sách mô hình đang sẵn sàng.
/sessions, /upload	POST	Đảm nhận quản lý phân cách phiên làm việc và tải lên tài liệu cần phân tích.
/query/stream	POST (SSE)	Phản hồi văn bản dạng Streaming theo tiêu chuẩn kết hợp truy xuất trích nguồn.
/agent	POST	Cổng API bảo mật dành riêng cho các tác vụ Coding Agent bên ngoài gọi vào.

Coding Agent & Giao Thức MCP

Lập Trình Tự Động & Kiểm Soát An Toàn

Agent được xây dựng trên bộ khung LangGraph tinh gọn, tương tác thông qua công cụ MCP chuyên biệt:

- **Auth Nghiêm Ngặt:** Yêu cầu header X-Agent-API-Key, lập tức phản hồi 401 nếu thiếu hoặc sai khóa.
- **MCP Filesystem:** Chỉ được phép tương tác trong giới hạn thư mục chỉ định WORKSPACE_DIR.
- **MCP Git:** Khóa hoạt động trong phạm vi thư mục dự án phát triển cụ thể.



```
main.ts -- vscode
src > main.ts > (e) activate
You, 3 days ago | 1 author (You)
15 import { workspace, ConfigurationChangeEvent, extensions } from "vscode";
14 import { getThemePaths } from "./helpers";
13 import utils, { UpdateTrigger } from "./utils";
12
11 export const activate = () => {
10   const paths = getThemePaths();
9
8   // regenerate on a fresh install if non-default config is set
7   if (utils.isFreshInstall() && !utils.isDefaultConfig()) {
6     utils.updateThemes(
5       options: utils.getConfiguration(),
4       paths,
3       trigger: UpdateTrigger.FRESH_INSTALL,
2     );
1   }
16
1   // regenerate the theme files when the config changes
2   workspace.onDidChangeConfiguration({ listener: (event: ConfigurationChangeEvent) => {
3     if (
4       event.affectsConfiguration(section: "workbench.colorTheme") &&
5       extensions.getExtension(extensionId: "catppuccin.catppuccin-vsc-icons")
6     ) {
7       const theme = workspace
8         .getConfiguration(section: "workbench")
9         .get<string>(section: "colorTheme");
10      const ctp_themes = {
11        "Catppuccin Latte": "catppuccin-latte",
12        "Catppuccin Frappé": "catppuccin-frappe",
13        "Catppuccin Macchiato": "catppuccin-macchiato",
14        "Catppuccin Mocha": "catppuccin-mocha",
15      };
16      if (Object.keys(ctp_themes).includes(searchElement: theme)) {
17        workspace
18          .getConfiguration(section: "workbench")
19          .update(section: "iconTheme", value: ctp_themes[theme], configurationTarget: true);
20      }
21    }
  }
}
```


Chiến Lược Bảo Mật & Vận Hành

Ranh Giới Bảo Mật

- Quản lý nghiêm ngặt khóa bí mật qua tệp cấu hình .env (không bao giờ lưu vào Git).
- Sử dụng cấu trúc định danh phiên dạng chuỗi ngẫu nhiên UUID.
- Áp dụng hạn mức truy vấn cứng: Tối đa 25 MB/file tệp, 15 truy vấn/phút và 10 lượt tải tài liệu/giờ cho mỗi IP.

Vận Hành Bền Bỉ

- Triển khai cụm Qdrant & LiteLLM thông qua Docker Compose độc lập, dễ nâng cấp.
- Chạy FastAPI & SPA dưới dạng một dịch vụ systemd user service ổn định.
- Kích hoạt tính năng Linger đảm bảo tiến trình tiếp tục chạy nền khi người quản trị thực hiện Logout.

Kết Quả Kiểm Thử Thực Tế

Hệ Thống Chạy Thực Tế End-To-End

Trải qua quy trình kiểm thử toàn diện trên Máy 2 với các chỉ số hoạt động xuất sắc:

- **React Production:** Đã Build tối ưu, kiểm tra hiển thị hoàn hảo trên cả Desktop và Mobile bằng bộ công cụ Playwright.
- **Router Hoạt Động:** LiteLLM nhận diện và phân phối mượt mà cả 5 nhóm mô hình được cấu hình sẵn.
- **Định Danh Chặt Chẽ:** API Agent phản hồi chính xác mã 200 khi có Key hợp lệ và 401 khi không có quyền truy cập.



Đánh Đổi & Lộ Trình Nâng Cấp



Image Sources



https://miro.medium.com/1*fnXT29TPST-V9hXiPkqahw.png

Source: jaredesign.medium.com



https://cdn.prod.website-files.com/5e593fb060cf877cf875dd1f/647e129b753c0df5ff23cc05_6479341d794b0caa0702742d_software-dashboard-webflow-template.png

Source: webflow.com